

# ML-прогнозирование длительности реализации RFC (Request for Change)

Machine Learning. Basic



**Меня хорошо видно  
& слышно?**



# Защита проекта

Тема:

**ML-прогнозирование длительности  
реализации RFC (Request for Change)**



**Коротких Антон**

# План защиты

Цель и задачи проекта

Какие технологии использовались

Что получилось

Выводы

Вопросы и рекомендации

# Цель и задачи проекта

## **Цель проекта:**

исследование прогнозирования длительности реализации продуктового запроса на изменение (Request for Change) с использованием методов машинного обучения

## **Задача:**

сравнить несколько моделей, которые по характеристикам RFC спрогнозируют предполагаемую длительность реализации в днях.

Данная задача актуальна для ИТ-компаний с продуктовым конвейером разработки, т.к. позволит оптимизировать планирование спринтов и релизов бизнес-задач.

# Какие технологии использовались

1. RandomForestRegressor - модель под задачи регрессии
2. KNeighborsRegressor - модель под задачи регрессии
3. VotingRegressor - ансамблевый метод
4. SimpleImputer - обработка пропусков в данных
5. OneHotEncoder - обработка категориальных данных
6. StandardScaler - нормализация данных
7. GridSearchCV - перебор комбинаций гиперпараметров



# План

1. Разведочный анализ данных (EDA) и определение целевой переменной
2. Визуализация распределения признаков и матрица корреляций
3. Предобработка данных
4. Пайплайн, моделирование и ансамбль
5. Сравнение метрик



# Разведочный анализ данных (EDA) и определение целевой переменной


|   | Id     | Priority | Systems | Integrations | Enterprise architecture | Technical debt | PM       | Days | Effort |
|---|--------|----------|---------|--------------|-------------------------|----------------|----------|------|--------|
| 0 | 893819 | 2        | 1       | 1            | in progress             | False          | Andrei H | 153  | NaN    |
| 1 | 893820 | 2        | 2       | 6            | in progress             | True           | Elena A  | 186  | NaN    |
| 2 | 893821 | 1        | 2       | 2            | in progress             | True           | Ksenia G | 107  | NaN    |
| 3 | 893822 | 2        | 3       | 7            | new                     | False          | Andrei H | 186  | NaN    |
| 4 | 893823 | 1        | 2       | 6            | done                    | False          | Ksenia G | 92   | NaN    |

- Id - идентификатор RFC
- Priority - бизнесовый приоритет (1-3)
- Systems - количество задействованных систем
- Integrations - количество межсистемных интеграций

- Enterprise architecture - статус готовности EA
- Technical debt - наличие технического долга
- PM - менеджер проекта
- Days - количество дней на реализацию
- Effort - трудозатраты



# Разведочный анализ данных (EDA) и определение целевой переменной



Эффективные менеджеры  
Andrei H и Elena A

Andrei M и Ksenia G  
имеют одинаковое количество  
проектов

# Разведочный анализ данных (EDA) и определение целевой переменной




С учетом задачи проекта о  
прогнозировании сроков


целевая переменная  
**Days**

# Визуализация распределения признаков


Распределение Enterprise architecture






Распределение Technical debt




Распределение PM



# Визуализация распределения признаков



# Матрица корреляций



| Признак                                          | Важность |
|--------------------------------------------------|----------|
| Numerical__Priority                              | 0.976957 |
| Numerical__Systems                               | 0.013560 |
| Categorical__Technical debt_True                 | 0.001862 |
| Categorical__Technical debt_False                | 0.001854 |
| Categorical__Enterprise architecture_done        | 0.001817 |
| Numerical__Integrations                          | 0.000982 |
| Categorical__PM_Andrei M                         | 0.000712 |
| Categorical__PM_Ksenia G                         | 0.000684 |
| Categorical__PM_Elena A                          | 0.000494 |
| Categorical__PM_Andrei H                         | 0.000479 |
| Categorical__Enterprise architecture_new         | 0.000385 |
| Categorical__Enterprise architecture_in progress | 0.000214 |


# Предобработка данных

```
# Удаляю ненужные столбцы
data = data.drop('Id', axis = 1)
data = data.drop('Effort', axis = 1)
# Разделение признаков
# т.к. 'Technical debt' содержит bool - привожу тип
categorical_cols = ['Enterprise architecture', 'Technical debt', 'PM']
numeric_cols = ['Priority', 'Systems', 'Integrations']
for col in categorical_cols:
    data[col] = data[col].astype(str)
```

```
# Создание пайплайна и препроцессинг
numeric_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='median')), # для заполнения пропусков
    ('scaler', StandardScaler()) # шкалирование данных для единообразия
])

categorical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='most_frequent')), # для заполнения пропусков
    ('onehot', OneHotEncoder(handle_unknown='ignore')) # преобразование категориальных
])
```

# Ансамбль и пайплайн




# Подбор гиперпараметров

```
# Подбор гиперпараметров моделей
param_grid = {
    'ensemble_knn_n_neighbors': [3, 5, 7], # количество соседей
    'ensemble_knn_weights': ['uniform', 'distance'], # с одинаковым и обратнопропорциональным
    'ensemble_rf_n_estimators': [100, 200], # количество деревьев решений
    'ensemble_rf_max_depth': [None, 10, 20] # максимальная глубина каждого дерева
}

grid_search = GridSearchCV(
    estimator=model,
    param_grid=param_grid,
    cv=5,
    scoring='r2',
    n_jobs=-1,
    verbose=1
)

grid_search.fit(X_train, y_train)
```





# Метрики ансамбля

| Метрика | Значение |
|---------|----------|
| MAE     | 6.3885   |
| MSE     | 157.3878 |
| RMSE    | 12.5454  |
| R2      | 0.9830   |

Лучшие гиперпараметры:

```
ensemble__knn__n_neighbors: 3  
ensemble__knn__weights: distance  
ensemble__rf__max_depth: 10  
ensemble__rf__n_estimators: 200
```

R2 на кросс-валидации: 0.9847



# Метрики в отдельности kNN и RandomForest

RandomForestRegressor

| Метрика | Значение |
|---------|----------|
|---------|----------|

|     |        |
|-----|--------|
| MAE | 3.6197 |
|-----|--------|

|     |         |
|-----|---------|
| MSE | 45.0832 |
|-----|---------|

|      |        |
|------|--------|
| RMSE | 6.7144 |
|------|--------|

|    |        |
|----|--------|
| R2 | 0.9951 |
|----|--------|

Лучшие параметры RF : {'max\_depth': 10, 'n\_estimators': 200}

KNeighborsRegressor

| Метрика | Значение |
|---------|----------|
|---------|----------|

|     |         |
|-----|---------|
| MAE | 10.8314 |
|-----|---------|

|     |          |
|-----|----------|
| MSE | 546.5783 |
|-----|----------|

|      |         |
|------|---------|
| RMSE | 23.3790 |
|------|---------|

|    |        |
|----|--------|
| R2 | 0.9408 |
|----|--------|




Лучшие параметры KNN: {'n\_neighbors': 3, 'weights': 'distance'}



# Сводное сравнение метрик

## СВОДНОЕ СРАВНЕНИЕ МОДЕЛЕЙ

|  | model                      | MAE     | MSE      | RMSE    | R2     |
|--|----------------------------|---------|----------|---------|--------|
|  | RandomForestRegressor      | 3.6197  | 45.0832  | 6.7144  | 0.9951 |
|  | KNeighborsRegressor        | 10.8314 | 546.5783 | 23.3790 | 0.9408 |
|  | VotingRegressor (ансамбль) | 6.3885  | 157.3878 | 12.5454 | 0.9830 |



# Выводы

1. Цель проекта достигнута - опробованы несколько моделей, проведено сравнение метрик.
2. Качество прогнозирования позволяет дальнейшее пилотирование на актуальных задачах с ретроспективным анализом результатов и донастройкой модели
3. Развитие и продолжение исследований с применением дополнительных самостоятельных моделей регрессии и применение в ансамбле



# Вопросы и рекомендации



если есть вопросы



если вопросов нет



**Спасибо за внимание!**

OTUS

